A2C v2 학습 결과 요약

월하사신 강화학습 실험 | 분석일 2026.10.31

약 10만 Step 학습으로 무작위 정책보다 진행 능력은 개선됐지만, 30소동 클리어에는 실패했다. 이전 A2C 대비 평균 도달 소동의 상승 폭은 작고, 판매 감소도 확인되지 않았다.

최종 평가: 각 정책 40판

지표	A2C v1	A2C v2
누적 학습 Step	100,170	100,170
30소동 클리어	0 / 40판 (0%)	0 / 40판 (0%)
평균 도달 소동	8.53	8.90
평균 완료 소동	7.53	7.90
평균 소환 횟수	13.65	14.53
평균 강화 횟수	4.62	5.47
평균 판매 횟수	5.40	5.85
평균 잔여 골드 (G)	213.82	205.90
최고 도달 소동	12	14

결과 해석

평균 도달 소동은 8.53에서 8.90으로 약 0.38소동 상승했다. 강화는 평균 4.63회에서 5.48회로 늘었지만, 판매도 5.40회에서 5.85회로 증가했다. 따라서 판매 반복 문제가 해결됐다고 보기는 어렵다.

v2의 최종 평가 도달 범위는 4~14소동이다. 무작위 정책의 평균 4.88소동보다는 높지만, 후반 웨이브를 평가할 수준에는 아직 도달하지 못했다.

도달 소동은 마지막으로 진입한 소동이다. 14소동 도달은 14소동 클리어를 뜻하지 않는다.

설정·학습 추이와 다음 실험

실제 실행 설정

항목	v2 실행값
학습	A2C / Adam / GAE / 배치당 단일 갱신
병렬 환경 및 배치	환경 15개 × 환경당 18 Step = 270 Step
학습률 / 할인율 / GAE lambda	0.0001 / 0.99 / 0.95
보상 배율	scale = 0.01
판매 손실 감점	손실 골드 1G당 0.15 × scale = 0.0015점 차감
행동 고정 감점	소환·강화·판매·웨이브 시작 모두 0
최종 잔여 골드 보상	goal_gold = 0 (비활성화)

저장된 config.json 기준으로 v1과 v2의 보상·공통 학습 수치는 같다. v2는 resume=false로 새로 시작했다. v1의 전체 설정 변경 이력은 저장 파일만으로 확인할 수 없으므로, 이 결과를 특정 보상 변경의 효과로 단정하지 않는다.

평가 추이

Step	평균 도달 소동	평균 판매 횟수	클리어율
0	4.90	8.88	0%
20,520	5.42	8.80	0%
51,300	7.83	7.58	0%
82,080	8.10	5.38	0%
100,170	8.90	5.85	0%

학습 중 종료된 게임은 3,281판, 업데이트는 371회이며 승리는 0판이다. 학습 중 최고 도달은 16소동으로, 최종 평가 최고 14소동과 구분해야 한다.

마지막 30회 평균 EV는 0.23로, 가치 예측의 설명력이 낮은 편이다. 다만 CSV만으로 특정 구현 오류나 실패 원인을 확정할 수는 없다.

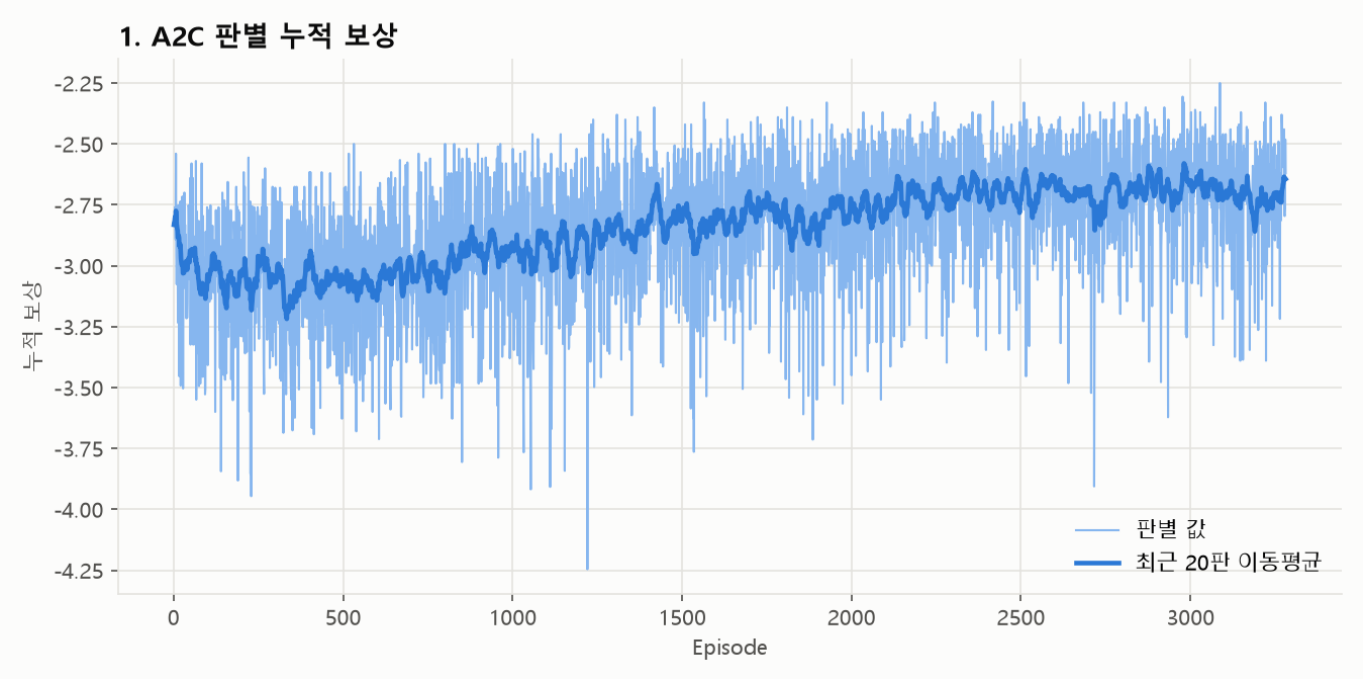
다음 실험 제안

설정과 게임 버전을 고정한 뒤 여러 학습 시드로 재평가한다. 웨이브별 구매·강화·판매·잔액 기록을 추가해 실패 시점과 판매 대상을 확인한다. 판매 제외 실험으로 반복 판매의 영향을 분리하고, 보상이나 학습률은 한 번에 한 항목씩 조정한다.

자료: results/a2c_pgh 및 results/a2c_pgh_v2의 config.json, evaluations.csv, final_eval.csv, episodes.csv, updates.csv. 부록은 v2 폴더의 원본 PNG 7장이다.

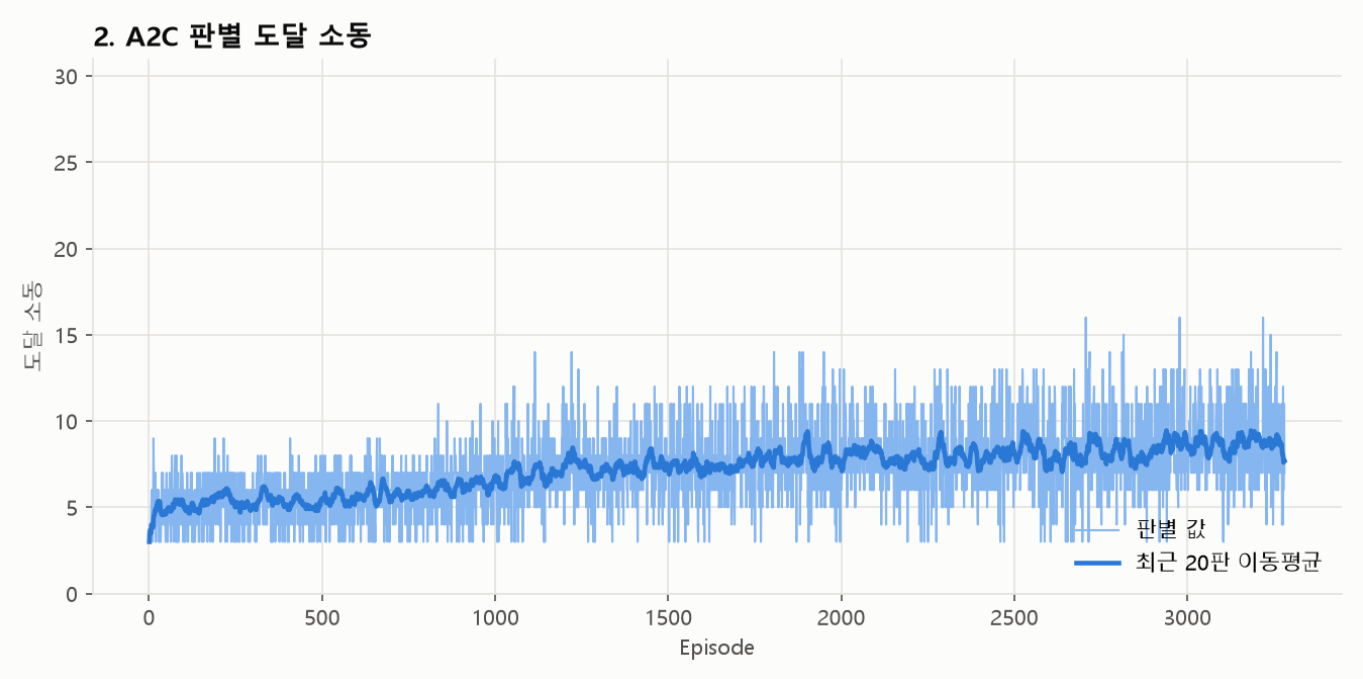
그래프 1. 판별 누적 보상

판별 원본 값과 이동평균이다. 전체 보상은 개선 추세지만 이것만으로 최종 승리 전략을 확보했다고 판단할 수 없다.



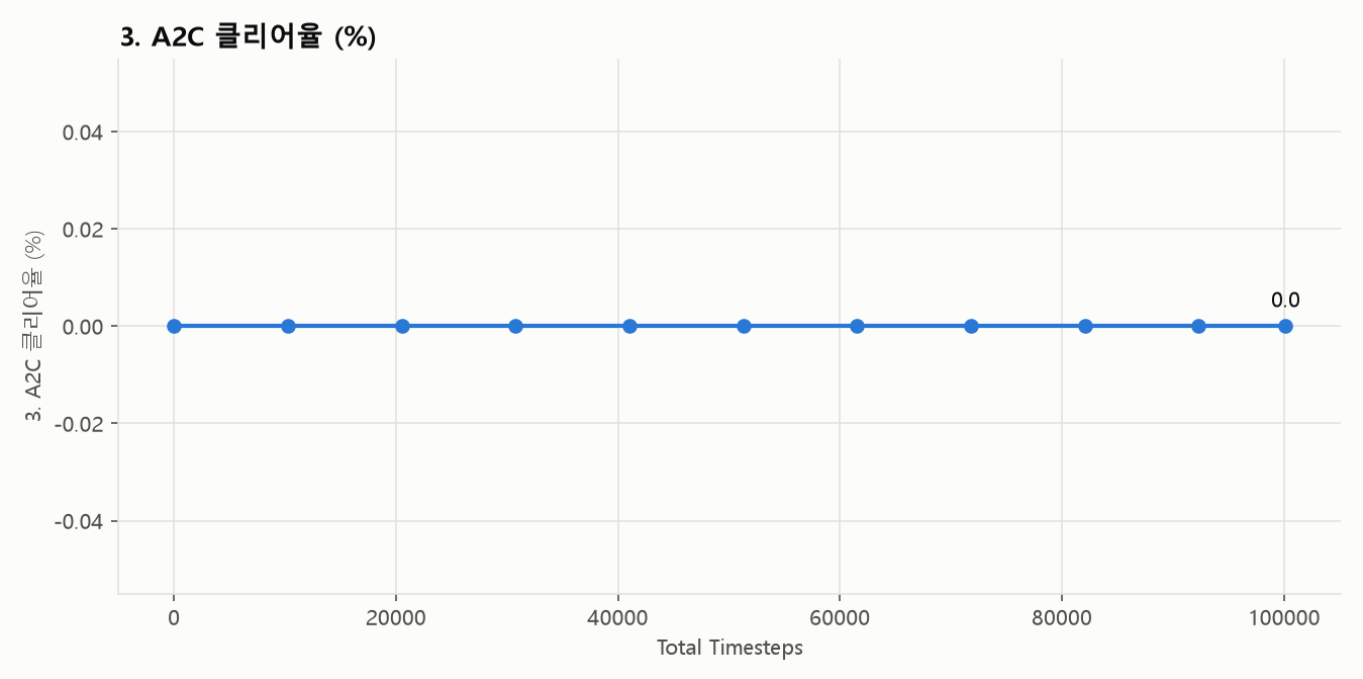
그래프 2. 판별 도달 소동

학습 중 최고 16소동까지 진입했다. 판별 편차가 크고 후반 소동 경험은 부족하다.



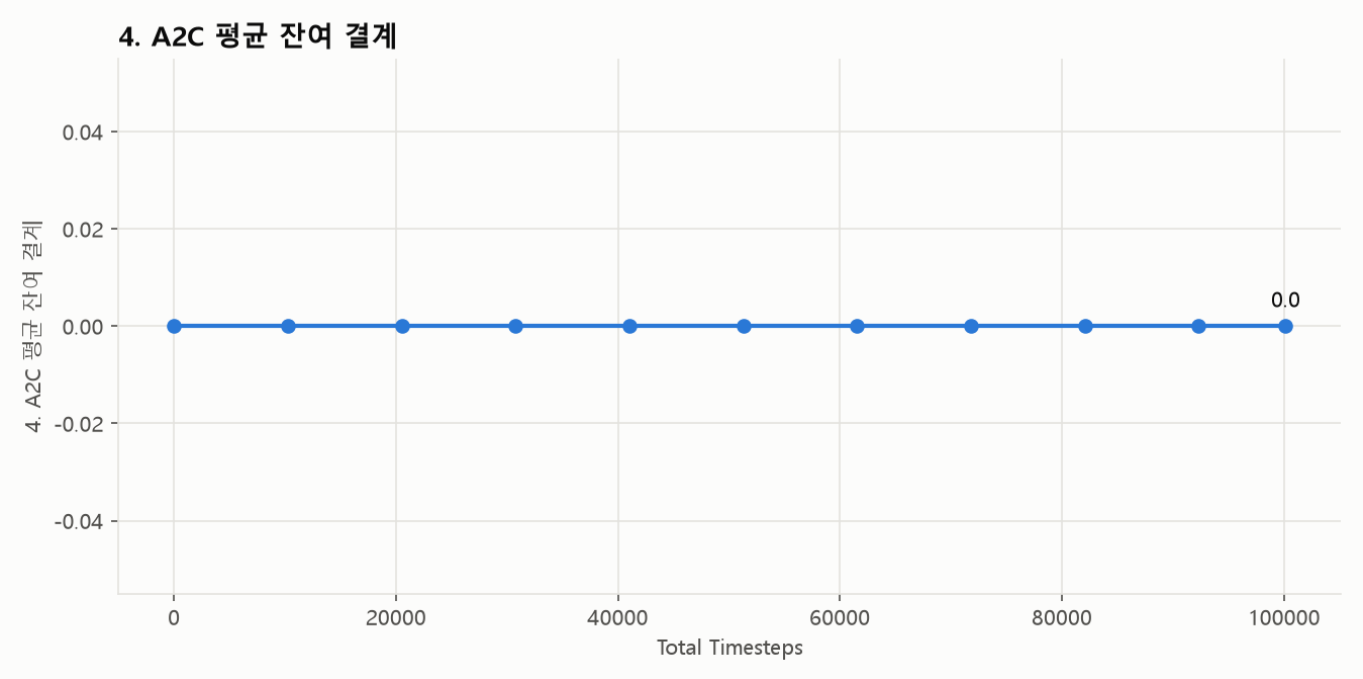
그래프 3. 정기 평가 클리어율

모든 정기 평가 및 최종 평가에서 30소동 클리어율은 0%다.



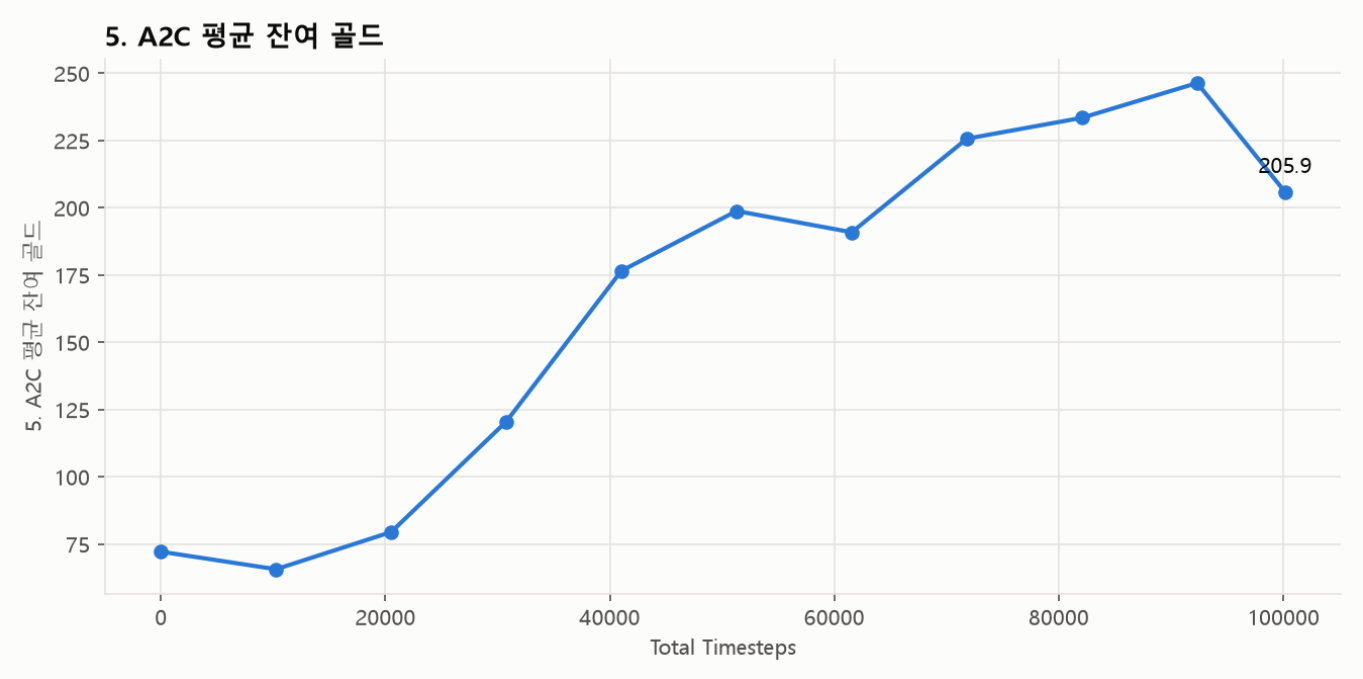
그래프 4. 평균 잔여 라이프

평가 판이 모두 패배로 종료되어 종료 시 라이프는 0이다.



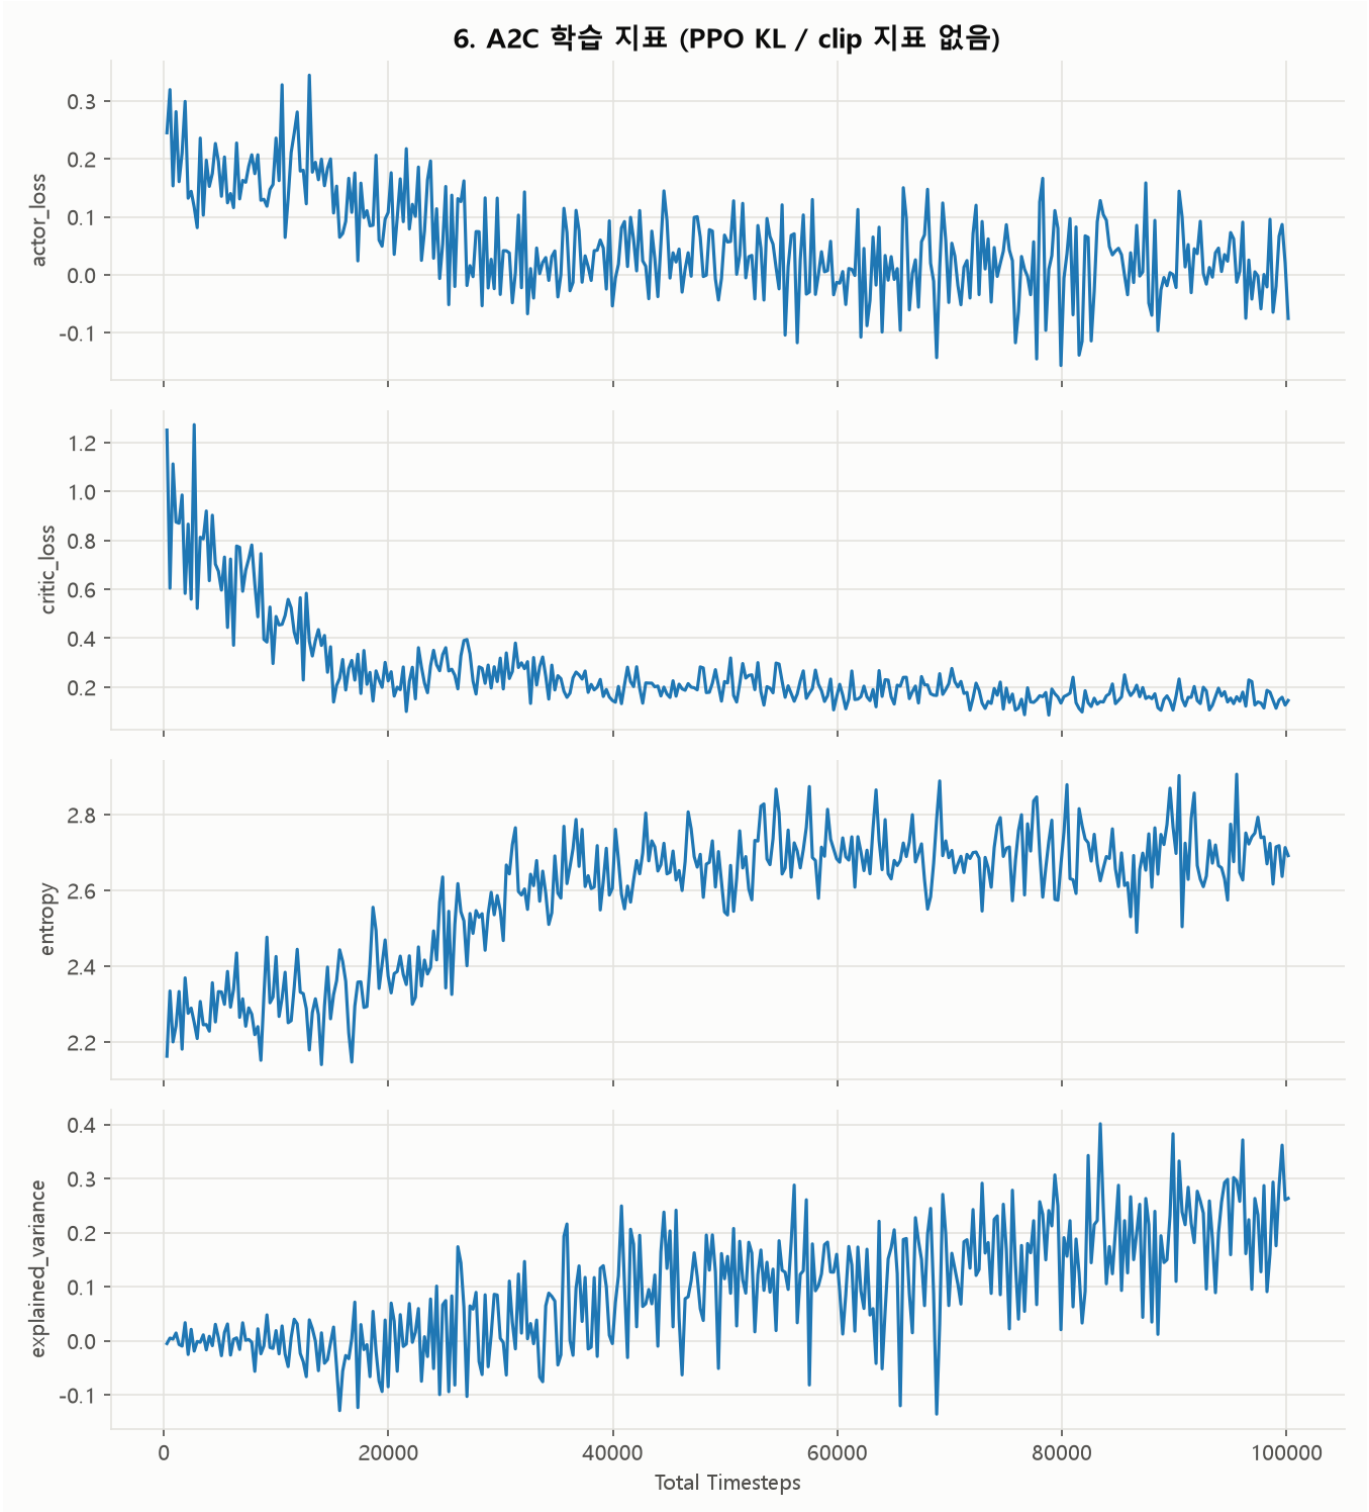
그래프 5. 평균 잔여 골드

최종 평가 평균 잔액은 약 206G다. 전투 중 처치로 획득한 골드도 포함하므로 의도적 저축으로 단정하지 않는다.



그래프 6. A2C 학습 지표

정책 손실·가치 손실·엔트로피·EV를 기록한다. A2C는 PPO의 확률 비율 clipping을 사용하지 않는다.



그래프 7. 최종 평가 요약

고정 시드 40판에서 무작위 정책과 A2C 정책을 비교한 원본 요약이다. 소동별 클리어율은 해당 소동에 진입한 판을 분모로 한다.

7. 최종 평가 요약 (고정 시드 40판, 30소동까지)

지표	무작위 정책	A2C 정책
30소동 클리어율	0%	0%
평균 도달 소동	4.9	8.9
평균 잔여 결계	0.0	0.0
평균 잔여 골드	75	206
평균 누적 Reward	-3.03	-2.74
평균 Episode 길이	27.1	34.8

