보상·패널티 설계 비교

1차: 판매 패널티 없음 / 2차: 판매 손실·판매 행동 패널티 활성화

두 실험의 공통 보상 배율은 scale = 0.01이다. 아래는 배율을 적용한 실제 학습 점수이며, 게임 내 골드와는 별개다.

보상·패널티 항목	1차 실험	2차 실험
웨이브 클리어	+0.02	+0.02
30소동 최종 클리어	+1.0	+1.0
보스 처치 (5 / 10 / 15소동)	+0.03 / +0.04 / +0.05	동일
보스 처치 (20 / 25 / 30소동)	+0.06 / +0.07 / +0.08	동일
30소동 승리 시 잔여 골드 1G당	+0.0001	+0.0001
라이프 1 손실당	-0.1	-0.1
게임 오버	-0.5	-0.5
소환·강화 1회당 (각각)	-0.005	-0.005
판매 1회당 고정 감점	없음	-0.005
판매 손실 골드 1G당 감점	없음	-0.0015
웨이브 시작 / 보스 웨이브 추가 라이프 감점	없음	없음

판매 예시

100G에 소환한 1레벨 타워를 60G에 판매하면 손실은 40G다. 2차 실험에서는 (0.5 + 0.15 × 40) × 0.01 = 0.065점이 차감된다.

잔여 골드 보상은 30소동 승리 시에만 지급한다. 두 실험 모두 승리가 없어 이번 결과에서는 해당 보상의 효과를 검증하지 못했다.

학습 결과 비교와 해석

약 5만 Step 시점 비교 / 각 정책 평가 40판 / 동일한 학습 시드 및 평가 시드 설정

평가 지표	1차: 51,300 Step	2차: 50,220 Step
30소동 클리어	0 / 40판 (0%)	0 / 40판 (0%)
평균 도달 소동	7.42	17.43
평균 소환 횟수	14.93	11.75
평균 강화 횟수	7.95	22.77
평균 판매 횟수	11.38	0.57
평균 종료 잔액 (G)	61.05	365.48
평균 누적 보상	-2.474	-2.277

판매 패널티를 적용한 2차 실험에서는 평균 판매 횟수가 약 95% 감소했고, 평균 도달 소동이 7.43에서 17.43으로 약 10단계 상승했다. 타워를 반복 판매하는 행동이 줄고 기존 타워를 강화하는 방향으로 개선됐다.

2차 최종 평가의 최고 도달은 28소동이지만 40판 모두 최종 클리어에는 실패했다. 판매 억제 효과는 확인했으나, 30소동 클리어 능력은 추가 학습과 평가가 필요하다.

이 비교는 학습 시드 1개에 대한 실험 결과다. 보상 함수가 달라졌으므로 누적 보상 수치만으로 성능을 판단하지 않고, 클리어율·도달 소동·판매 횟수를 함께 본다.

첨부 그래프 해석 시 주의

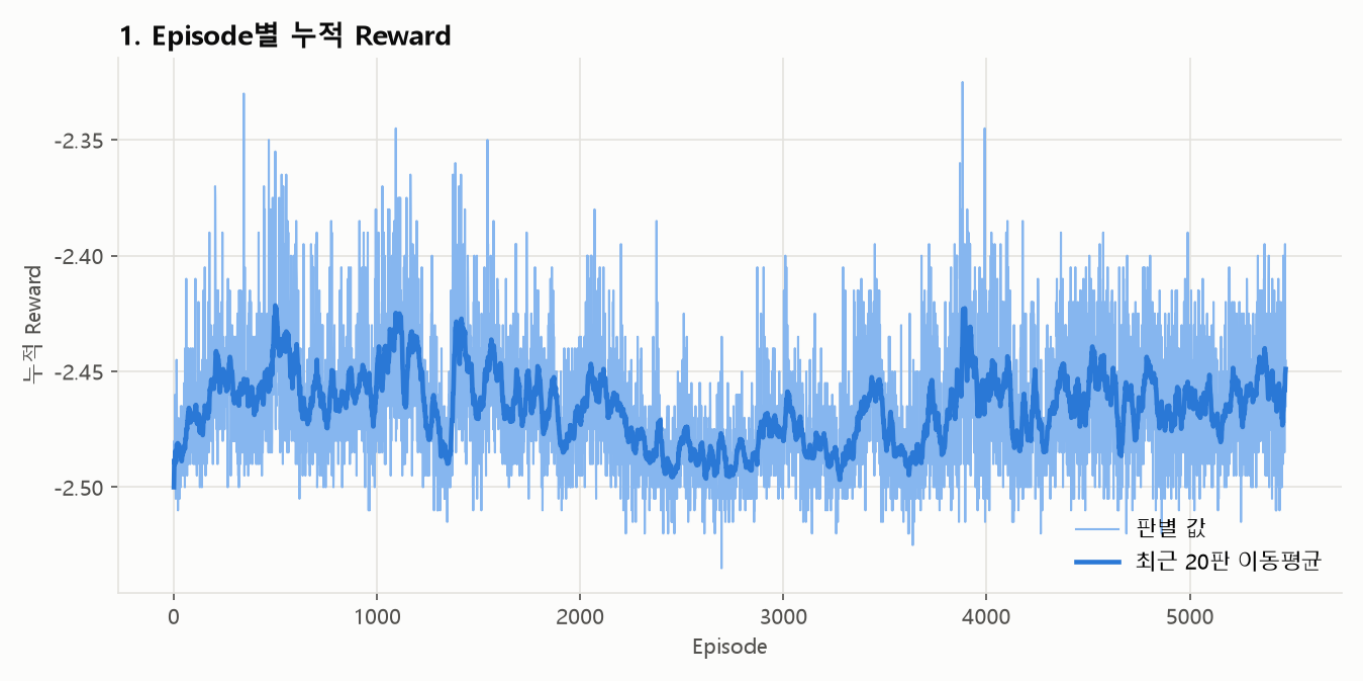
뒤의 원본 PNG 14장은 각각의 전체 실행 결과다. 1차는 300,240 Step, 2차는 50,220 Step까지의 기록이므로 가로축과 최종 요약의 학습량이 다르다. 위 표는 이 차이를 줄이기 위해 약 5만 Step 평가끼리 비교했다.

자료: 각 결과 폴더의 config.json, evaluations.csv, final_eval.csv 및 PNG 7장. 원본 데이터와 그래프는 수정하지 않았다.

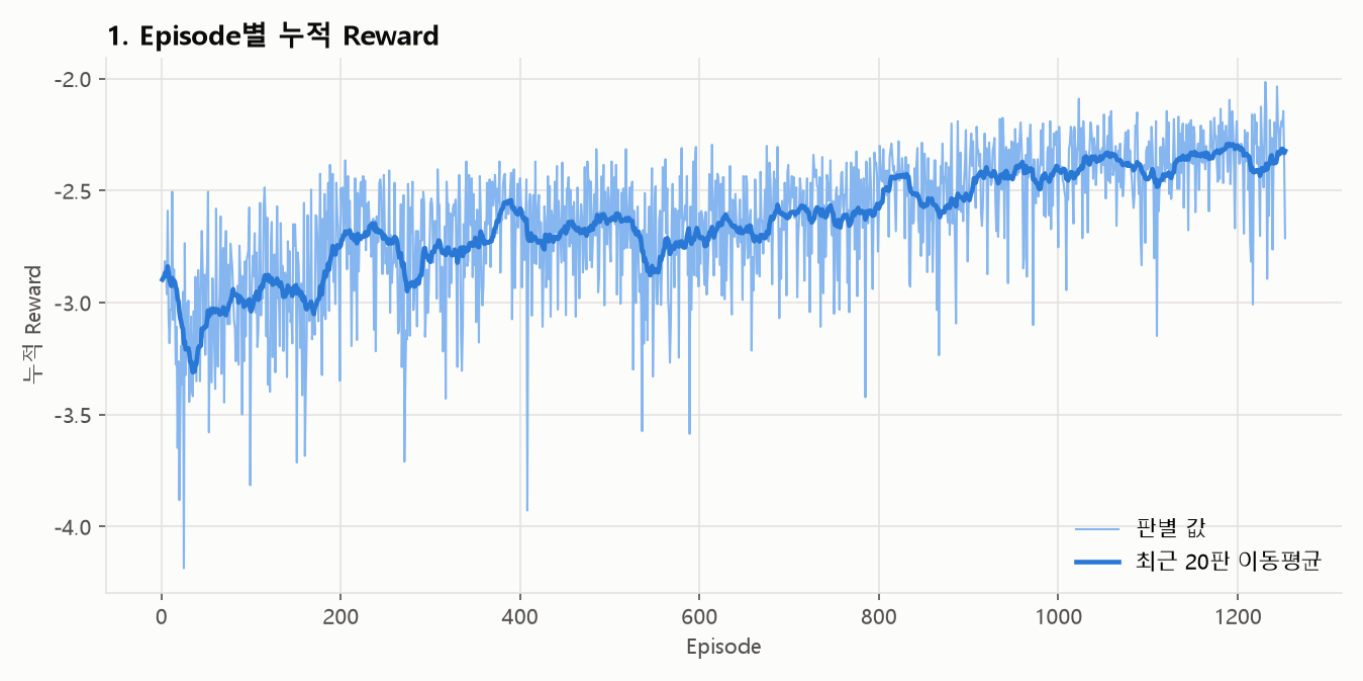
그래프 비교 1 | 판별 누적 보상

보상 함수가 다르므로 두 실험의 세로축 수치를 직접적인 성능 순위로 해석하지 않는다.

1차 실험 | 전체 300,240 Step



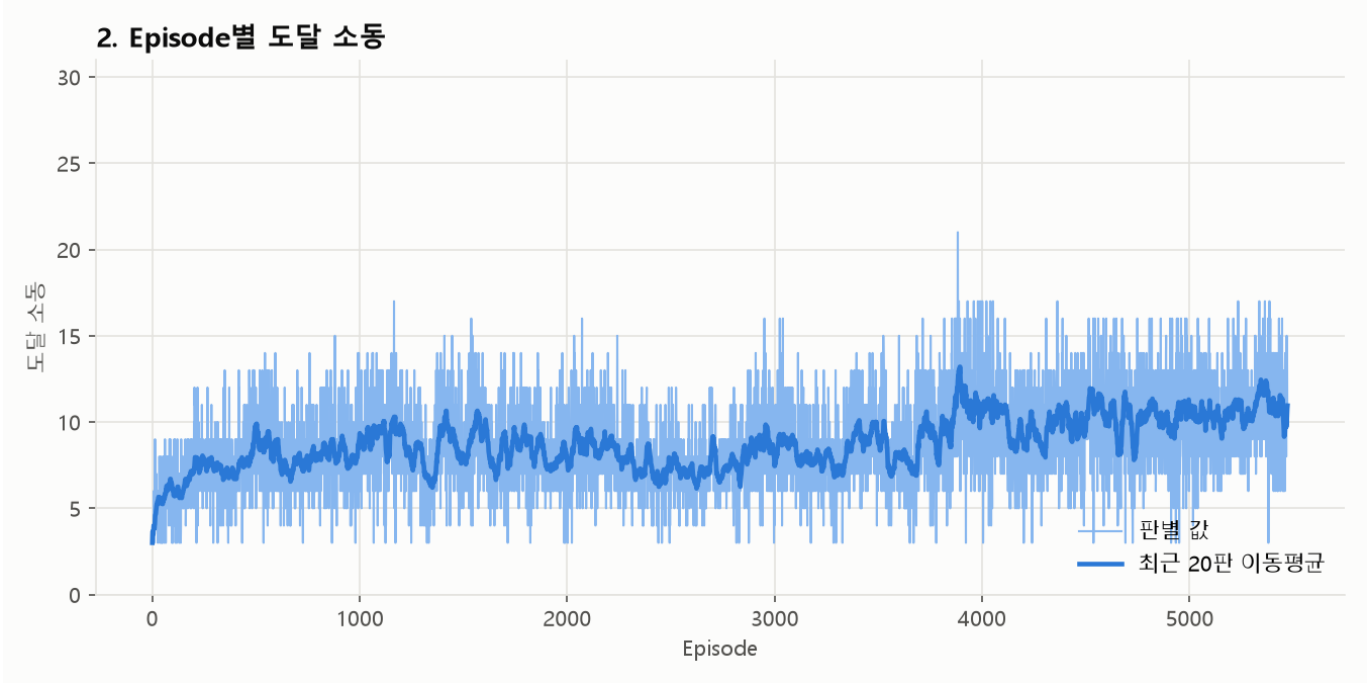
2차 실험 | 전체 50,220 Step



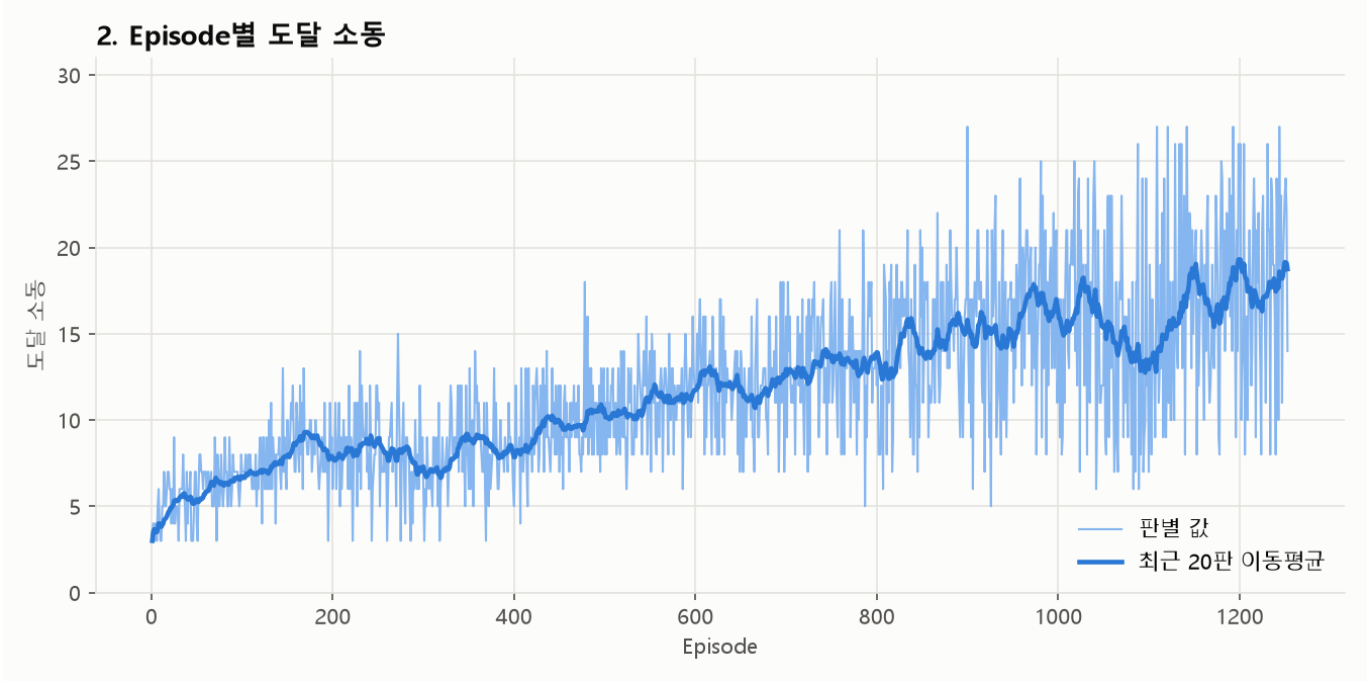
그래프 비교 2 | 판별 도달 소동

도달 소동은 마지막으로 진입한 소동이다. 해당 소동을 클리어했다는 의미는 아니다.

1차 실험 | 전체 300,240 Step



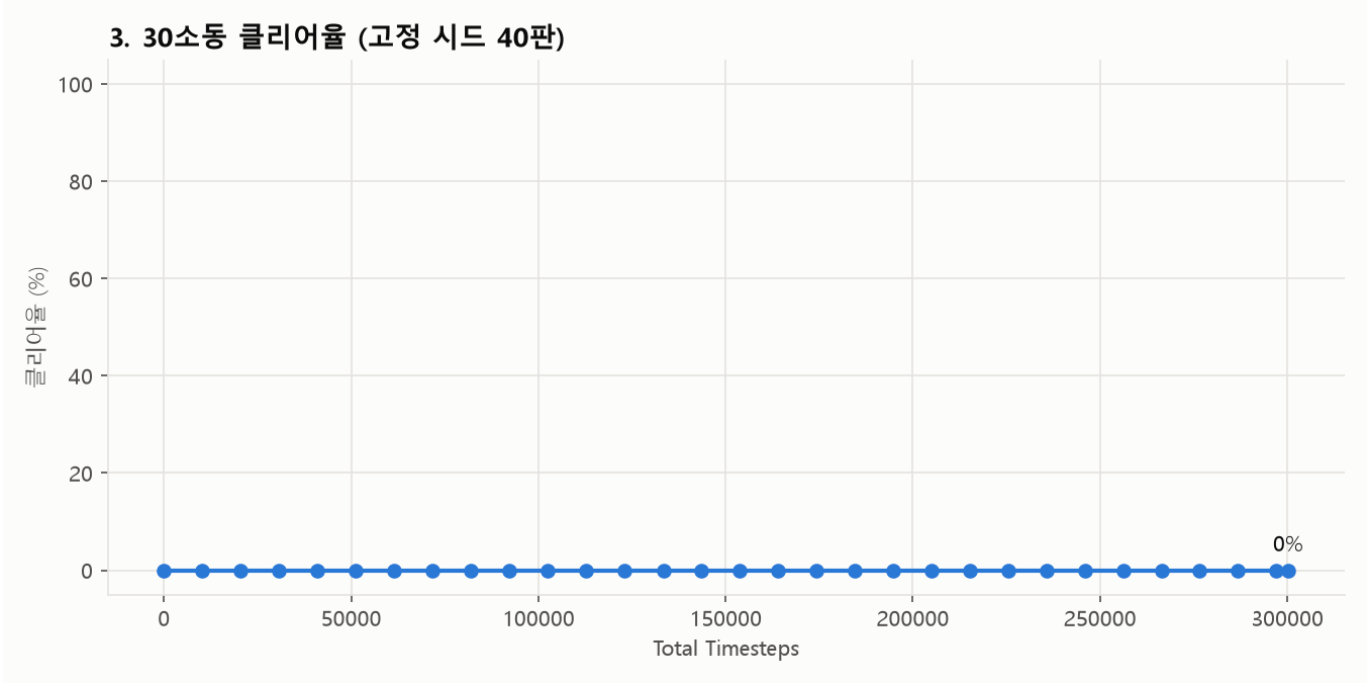
2차 실험 | 전체 50,220 Step



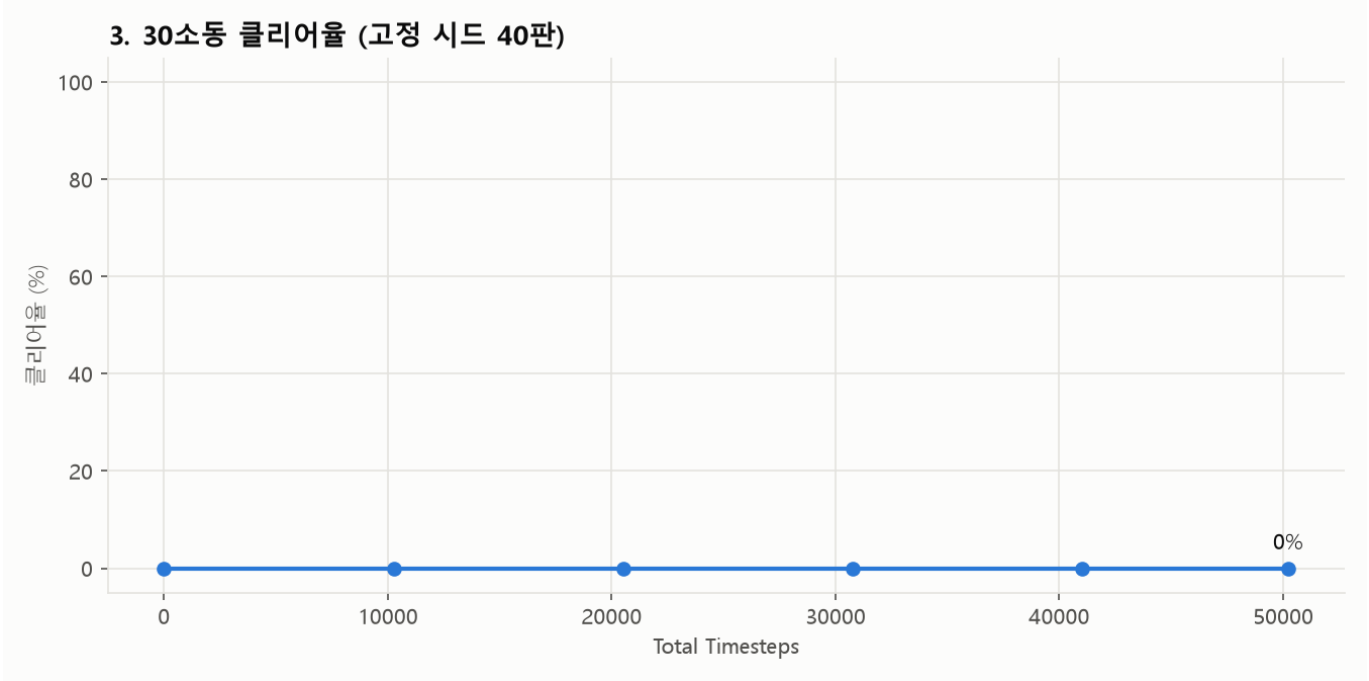
그래프 비교 3 | 정기 평가 클리어율

두 실험 모두 평가에서 최종 클리어율 0%를 기록했다.

1차 실험 | 전체 300,240 Step



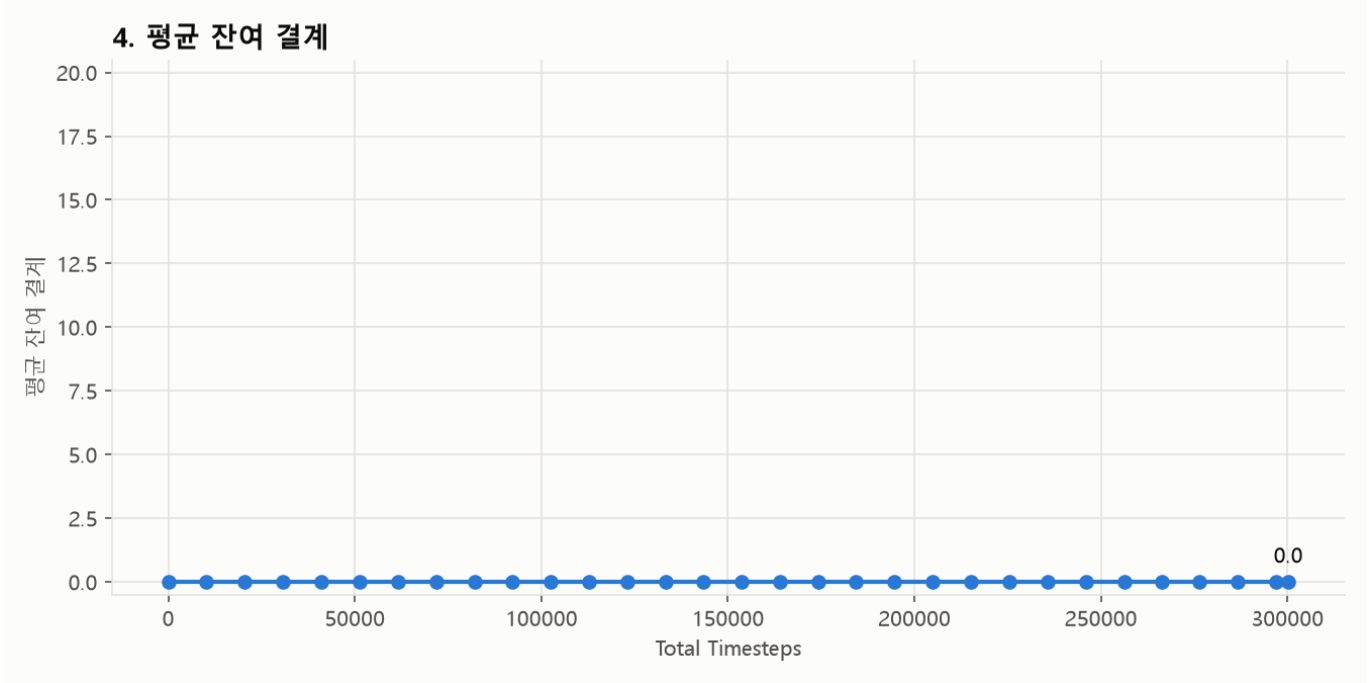
2차 실험 | 전체 50,220 Step



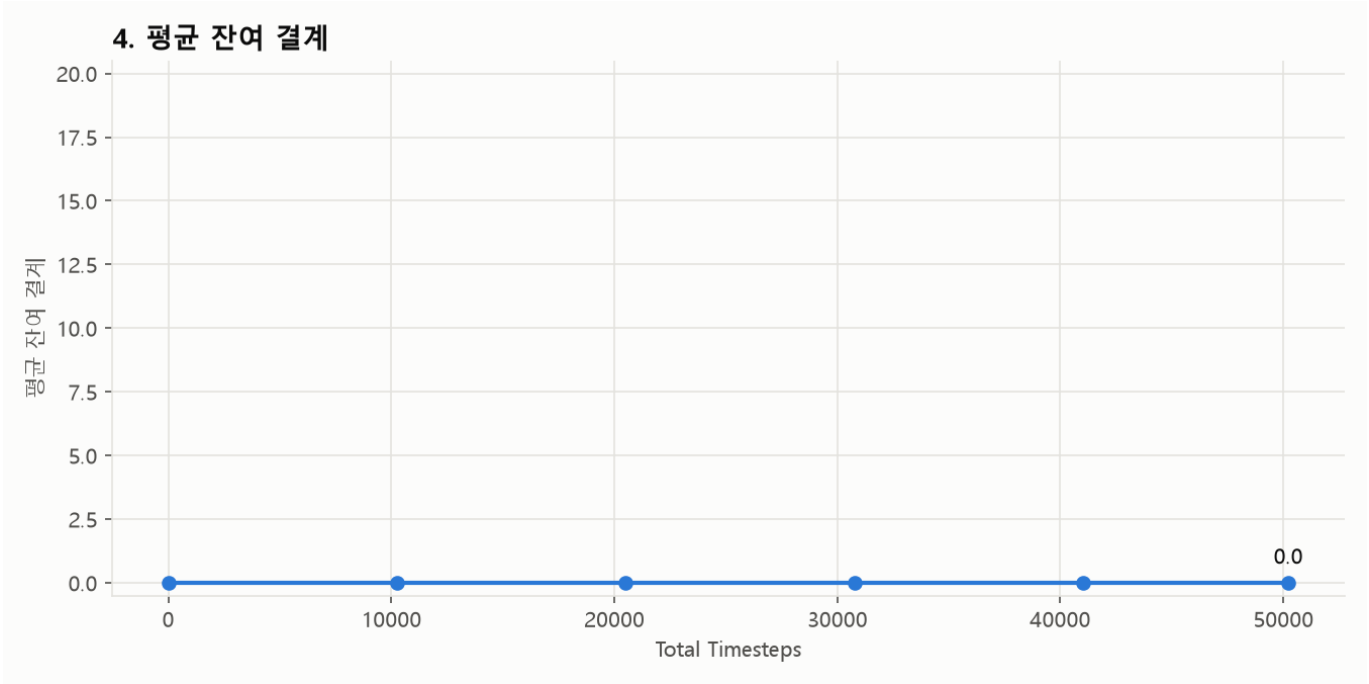
그래프 비교 4 | 평균 잔여 라이프

모든 평가 판이 패배로 종료되어 종료 시 잔여 라이프는 0이다.

1차 실험 | 전체 300,240 Step



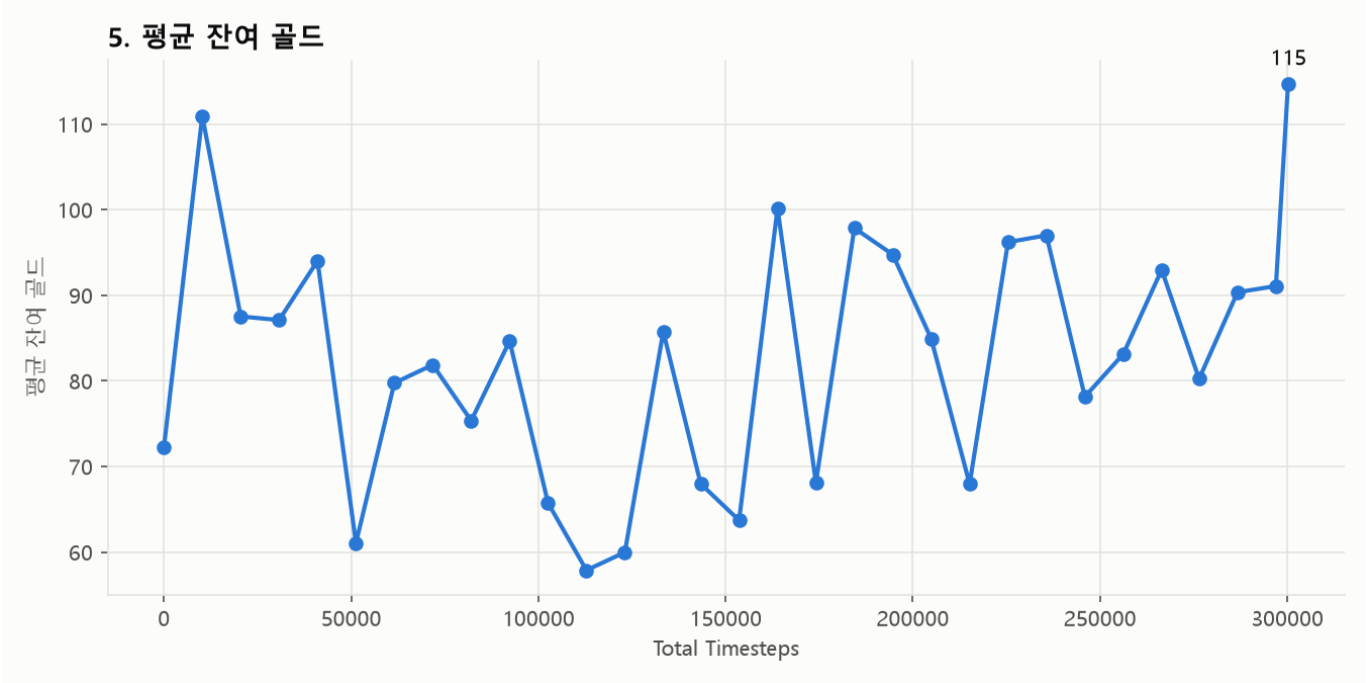
2차 실험 | 전체 50,220 Step



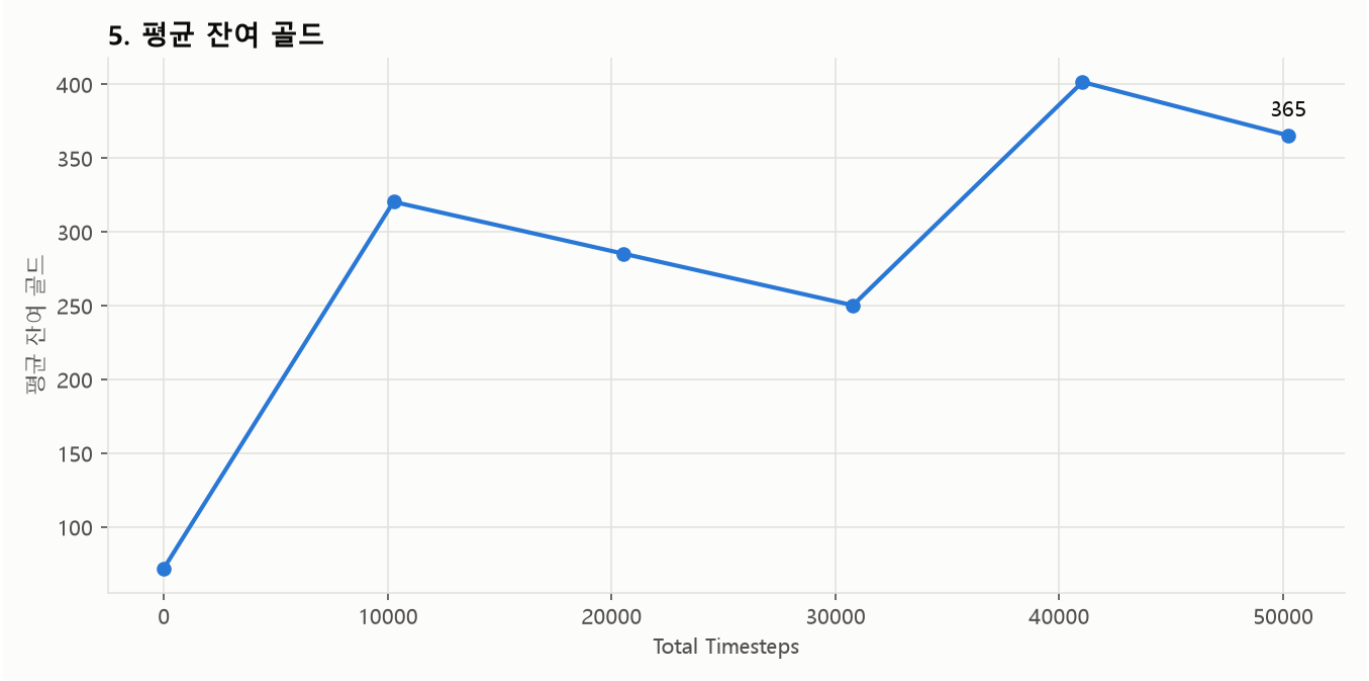
그래프 비교 5 | 평균 잔여 골드

종료 잔액에는 전투 중 획득한 골드가 포함된다. 잔액만으로 의도적 저축을 판단할 수 없다.

1차 실험 | 전체 300,240 Step

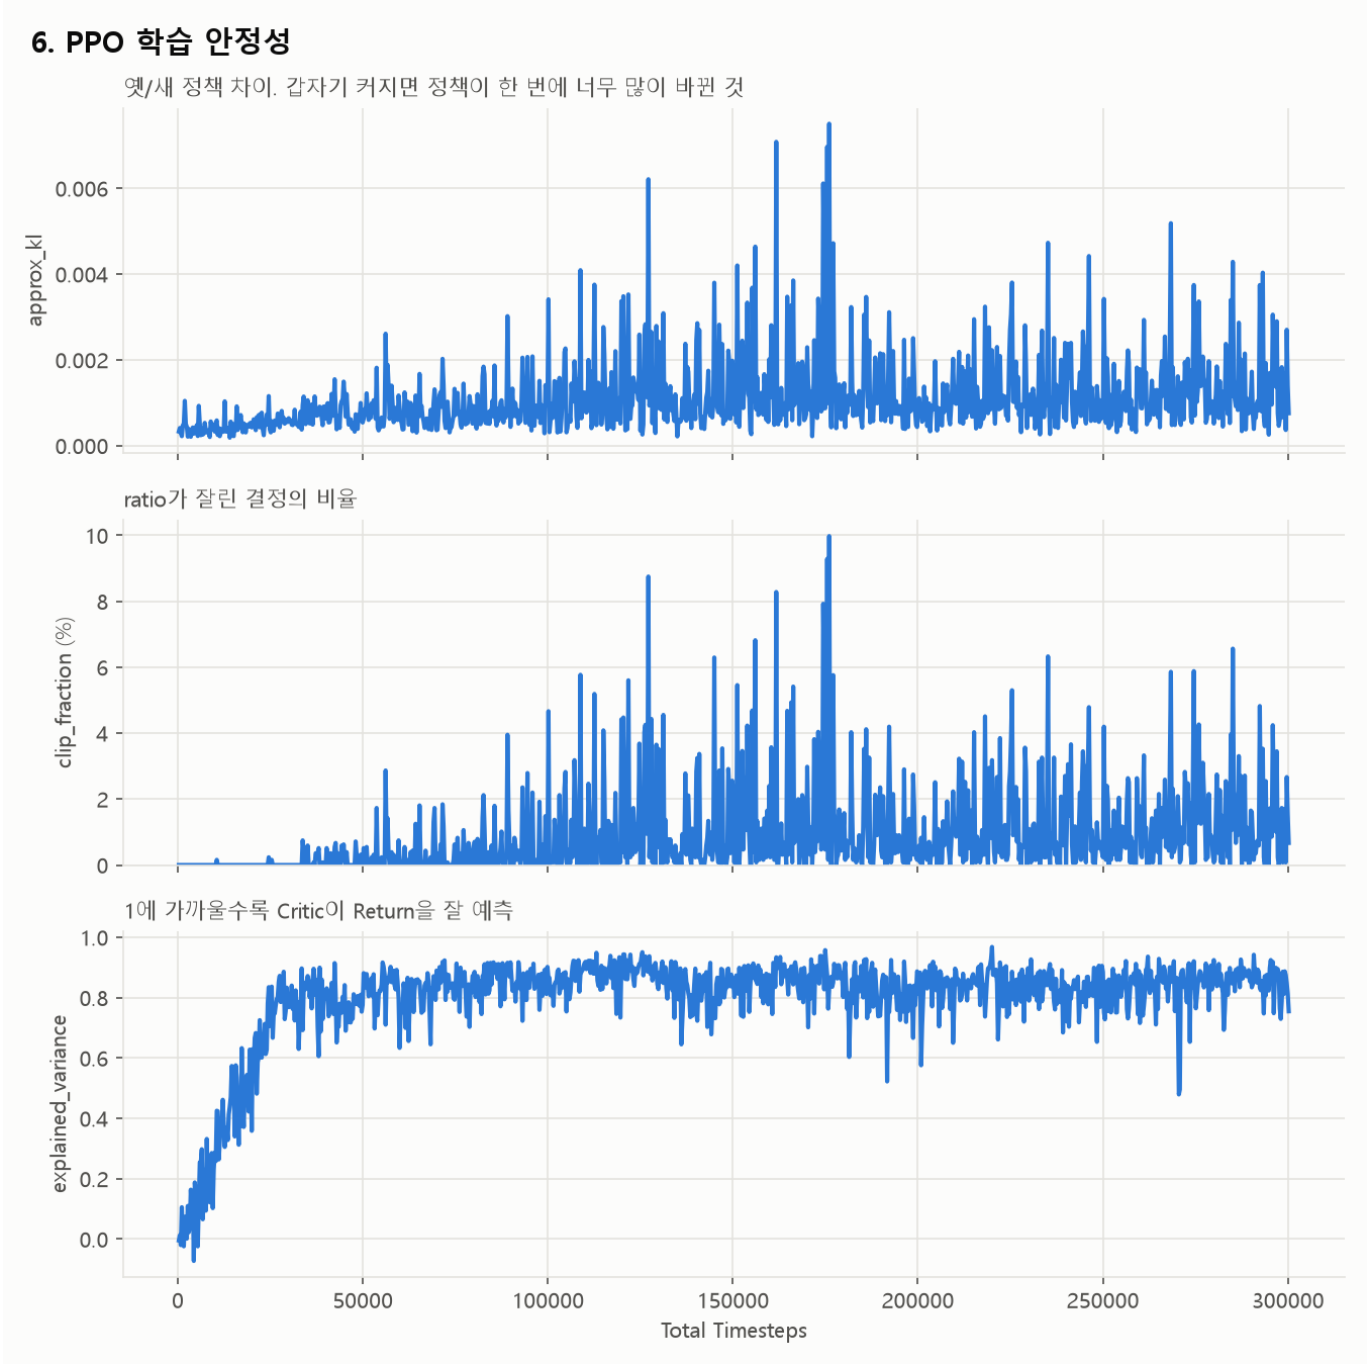


2차 실험 | 전체 50,220 Step



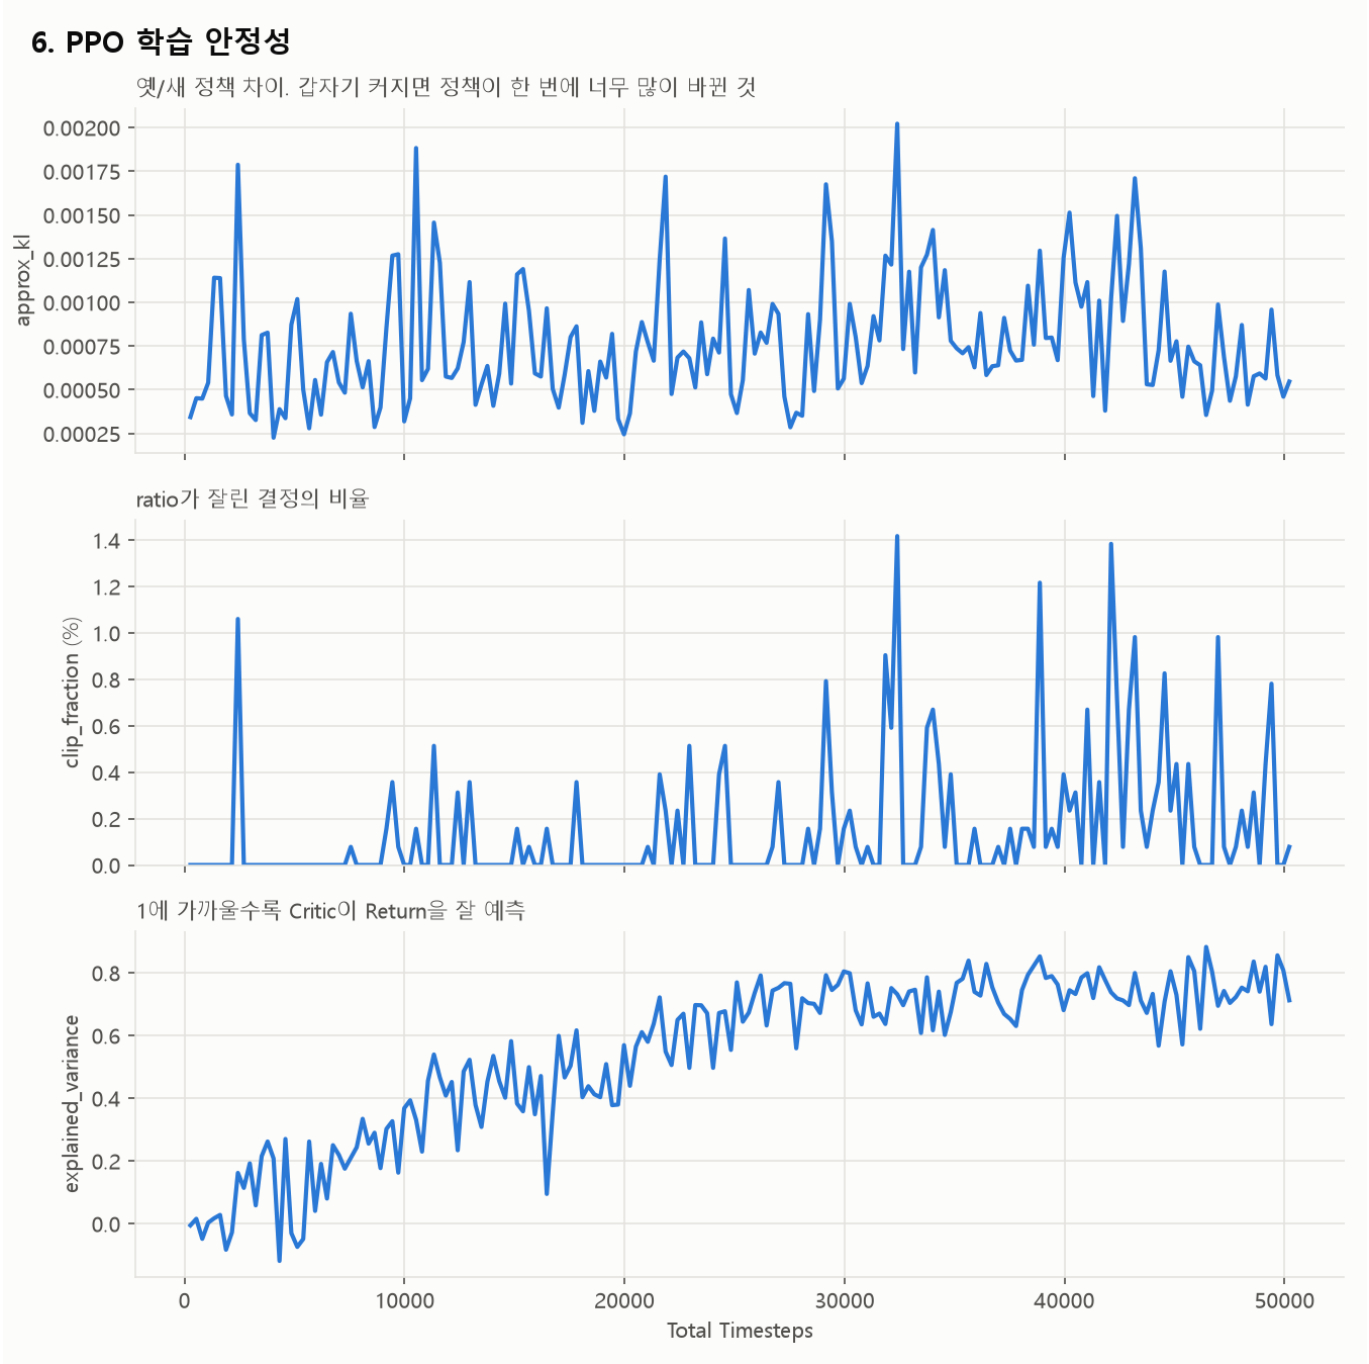
PPO 학습 안정성 | 1차 실험

1차 실험 | 전체 300,240 Step / KL·clip 비율은 정책 변화, EV는 가치 예측의 설명력을 나타낸다. 게임 승리 여부와는 별개의 지표다.



PPO 학습 안정성 | 2차 실험

2차 실험 | 전체 50,220 Step / KL·clip 비율은 정책 변화, EV는 가치 예측의 설명력을 나타낸다. 게임 승리 여부와는 별개의 지표다.



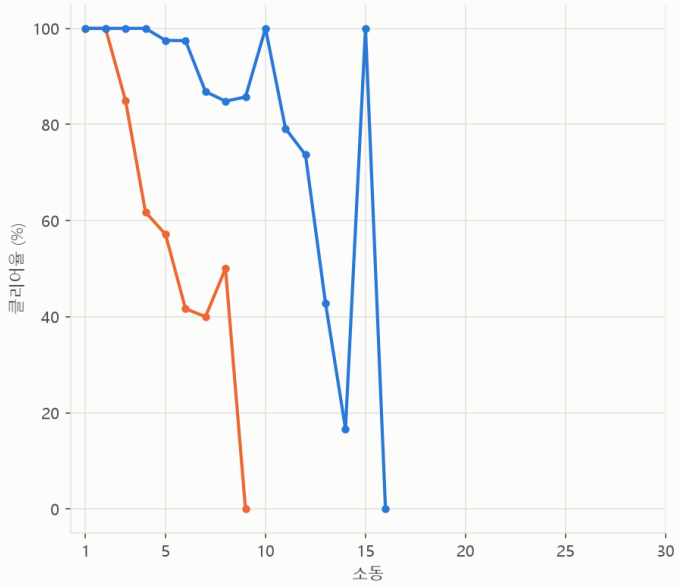
최종 평가 요약 | 1차 실험

1차 실험 | 전체 300,240 Step / 각 실험의 마지막 모델 평가다. 1차 30만 Step과 2차 5만 Step이므로 학습량이 다르다.

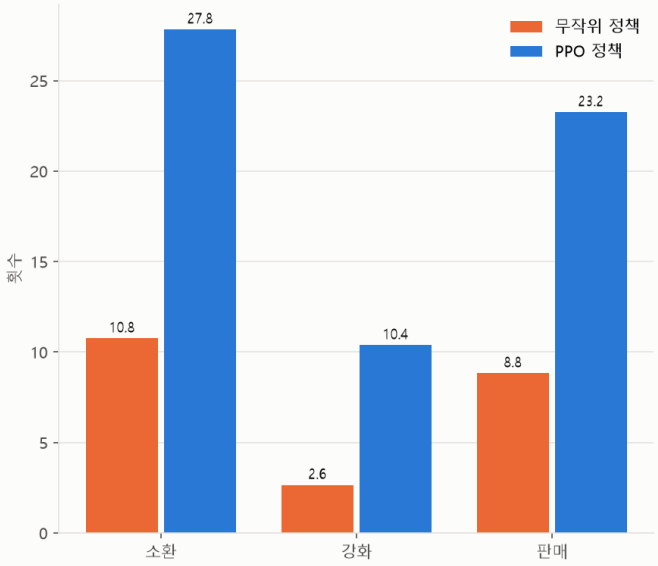
7. 최종 평가 요약 (고정 시드 40판, 30소동까지)

지표	무작위 정책	PPO 정책
30소동 클리어율	0%	0%
평균 도달 소동	4.9	10.7
평균 잔여 결계	0.0	0.0
평균 잔여 골드	75	115
평균 누적 Reward	-2.49	-2.45
평균 Episode 길이	27.1	72.1

소동별 클리어율 (어디서 막히는가)



한 판 평균 행동 횟수 (어떤 전략인가)



최종 평가 요약 | 2차 실험

2차 실험 | 전체 50,220 Step / 각 실험의 마지막 모델 평가다. 1차 30만 Step과 2차 5만 Step이므로 학습량이 다르다.

7. 최종 평가 요약 (고정 시드 40판, 30소동까지)

지표	무작위 정책	PPO 정책
30소동 클리어율	0%	0%
평균 도달 소동	4.9	17.4
평균 잔여 결계	0.0	0.0
평균 잔여 골드	75	365
평균 누적 Reward	-3.15	-2.28
평균 Episode 길이	27.1	52.5

